LAPORAN UTS GRAF SAINS DATA
RetailRocket Dataset — Neo4j, VSM, Similarity, dan Analytics

Nama : Seilvy Kusumah Dwi Ambado

NIM : 23031554034

Kelas : 2023 B

Mata Kuliah: Graf Sains Data

1. Ringkasan Dataset dan Lingkungan

Dataset yang digunakan adalah RetailRocket. File yang disebut dalam pengerjaan adalah events.csv, training.csv, dan testing.csv. Data interaksi direpresentasikan sebagai simpul Visitor dan Item, dengan relasi interaksi VIEWED, ADDED_TO_CART, dan BOUGHT. Analisis dilakukan menggunakan Neo4j serta Python (pandas, SciPy, scikit-learn, NetworkX, dan pustaka terkait).

Catatan periode dataset yang telah ditetapkan dalam pengerjaan: training 9 Mei–9 Juli 2015 UTC; testing 18 Juli–2 Agustus 2015 UTC.

2. Komposisi graf yang sudah diketahui

Jenis	Jumlah	Keterangan
Visitor	533.857	Jumlah simpul pada hasil query Neo4j yang terakhir dilaporkan
Item	153.489	Jumlah simpul pada hasil query Neo4j yang terakhir dilaporkan
Relasi interaksi	1.048.446	VIEWED + ADDED_TO_CART + BOUGHT
SIMILAR_TO_USER	5	Relasi similarity user-user yang diimpor
SIMILAR_TO_ITEM	5	Relasi similarity item-item yang diimpor
Total relasi setelah similarity	1.048.456	Interaksi + 10 relasi similarity

3. Komposisi Subgraph: Jenis dan Jumlah Simpul dengan Python API

Tujuan: memperoleh komposisi subgraph, menghitung jenis simpul beserta jumlah masing-masing, dan menjelaskan Cypher yang digunakan.

Cypher untuk menghitung simpul berdasarkan label

```
MATCH (n)
RETURN labels(n) AS jenis_simpul, count(n) AS jumlah_simpul
ORDER BY jenis_simpul;
```

Penjelasan: MATCH (n) mengambil semua simpul. labels(n) mengembalikan label simpul, misalnya Visitor atau Item. count(n) menghitung simpul pada kelompok label tersebut, lalu ORDER BY mengurutkan hasil.

Contoh Python API untuk membaca hasil query Neo4j

```
from neo4j import GraphDatabase

URI = "bolt://localhost:7687"
AUTH = ("neo4j", "?????")

driver = GraphDatabase.driver(URI, auth=AUTH)

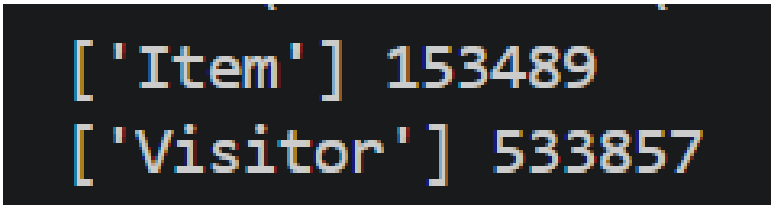
query = """
MATCH (n)
RETURN labels(n) AS jenis_simpul, count(n) AS jumlah_simpul
ORDER BY jenis_simpul
"""

with driver.session() as session:
    for record in session.run(query):
        print(record["jenis_simpul"], record["jumlah_simpul"])

driver.close().
```

Hasil query dan interpretasi

Angka yang telah dilaporkan dari graf: Visitor = 533.857 dan Item = 153.489. Cocokkan kembali dengan hasil query komposisi simpul di atas sebelum finalisasi laporan.



4. VSM pada Simpul User: Karakteristik dan Proyeksi

Vector Space Modelling (VSM) merepresentasikan setiap user sebagai vektor interaksi terhadap item. Baris matriks mewakili user, kolom mewakili item, dan nilai sel menunjukkan adanya interaksi (pada implementasi biner, 1 berarti berinteraksi dan 0 berarti tidak).

Hasil numerik yang telah diperoleh

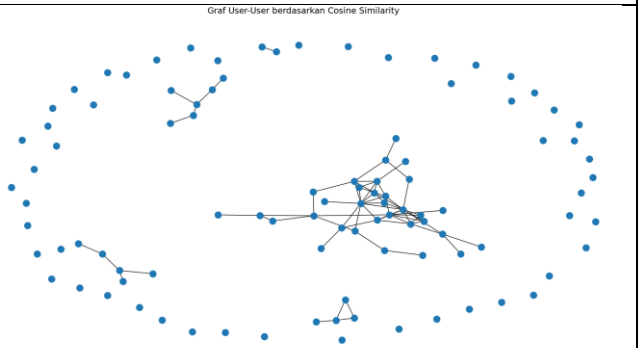
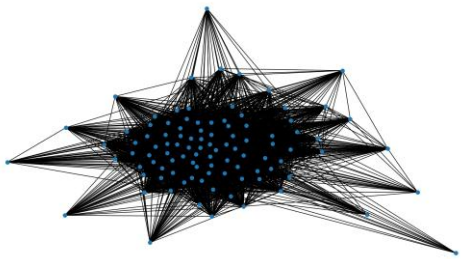
- Jumlah interaksi unik User–Item: 955.633
- Jumlah user pada matriks: 627.580
- Jumlah item pada matriks: 166.288
- Shape matriks User–Item: (627580, 166288)
- Jumlah nilai non-zero (nnz): 955.633

- Sparsity: sekitar 0,999991 atau sekitar 99,9991%
- Proyeksi User–User teoritis: 627580 × 627580
- Contoh graf User–User berukuran 100 simpul: 72 sisi

Matriks sangat sparse: sebagian besar pasangan user-item tidak memiliki interaksi. Karena proyeksi penuh User–User berukuran sangat besar, pengerjaan menggunakan sampel 100 user untuk visualisasi jaringan.

plot yang dilampirkan

Masukkan cuplikan kode VSM yang benar-benar digunakan, serta plot NetworkX dari sampel user-user. Jangan menyatakan plot sudah dilampirkan sebelum memasukkan gambar aktual.

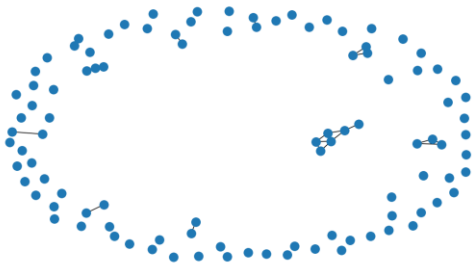
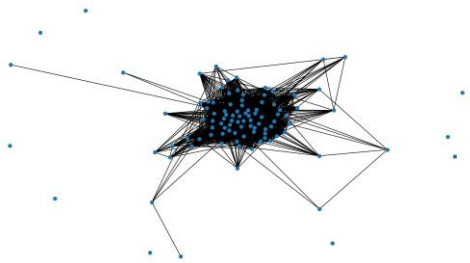
VSM User	VSM User Network
	

5. VSM pada Simpul Item: Karakteristik dan Proyeksi

Untuk proyeksi Item–Item, setiap item direpresentasikan berdasarkan pola user yang berinteraksi dengannya. Secara konseptual, matriks Item–User merupakan transpose dari matriks User–Item.

- Jumlah item pada matriks: 166.288
- Jumlah user pada matriks: 627.580
- Shape matriks Item–User: (166288, 627580)
- Proyeksi Item–Item teoritis: 166288 × 166288
- Contoh graf Item–Item berukuran 100 simpul: 21 sisi

Karena proyeksi penuh Item–Item juga berukuran besar, visualisasi dilakukan pada sampel 100 item.

VSM Item	VSM Item Network
	

6. Perbandingan Proyeksi User–User dan Item–Item

Berdasarkan ukuran matriks, proyeksi Item–Item lebih kecil daripada User–User: 166.288 simpul potensial dibandingkan 627.580. Secara teoritis, matriks persegi Item–Item berisi sekitar 27,65 miliar posisi, sedangkan User–User sekitar 393,86 miliar posisi. Keduanya tetap terlalu besar untuk dibentuk sebagai matriks dense di memori biasa.

Kesimpulan : proyeksi Item–Item lebih efektif/efisien dari sisi jumlah simpul dan ukuran ruang proyeksi. Namun, keputusan akhir sebaiknya mempertimbangkan sparsity, biaya komputasi, tujuan analisis (rekomendasi item atau kemiripan user), serta hasil pengukuran runtime/memori bila tersedia.

7. Similarity pada Graf Terproyeksi

7(a). Lima record dengan similarity tertinggi

Similarity dihitung dengan cosine similarity pada sampel 100 user dan 100 item yang dipilih berdasarkan interaksi VIEW. File hasil yang dilaporkan: similarity_user_top5.csv dan similarity_item_top5.csv.

Lima pasangan User–User

No.	Visitor 1	Visitor 2	Similarity
1	1119917	468309	0.4566025759
2	518659	1336835	0.1869086491
3	527307	856874	0.1806388957
4	1357576	1094964	0.1801534773
5	825321	73449	0.1726286821

Lima pasangan Item–Item

No.	Item 1	Item 2	Similarity
1	315545	320494	0.2620142134
2	309778	257040	0.2127197876
3	315545	422425	0.2118042788
4	299222	318333	0.1927048089
5	234255	318333	0.1573644019

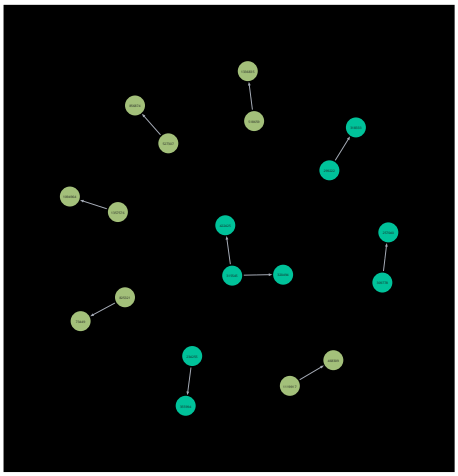
Cypher untuk mengambil 5 relasi similarity tertinggi

```
MATCH (u1:Visitor)-[r:SIMILAR_TO_USER]->(u2:Visitor)
RETURN u1.visitorId AS visitor_1,
    u2.visitorId AS visitor_2,
    r.similarity AS similarity
ORDER BY similarity DESC
LIMIT 5;

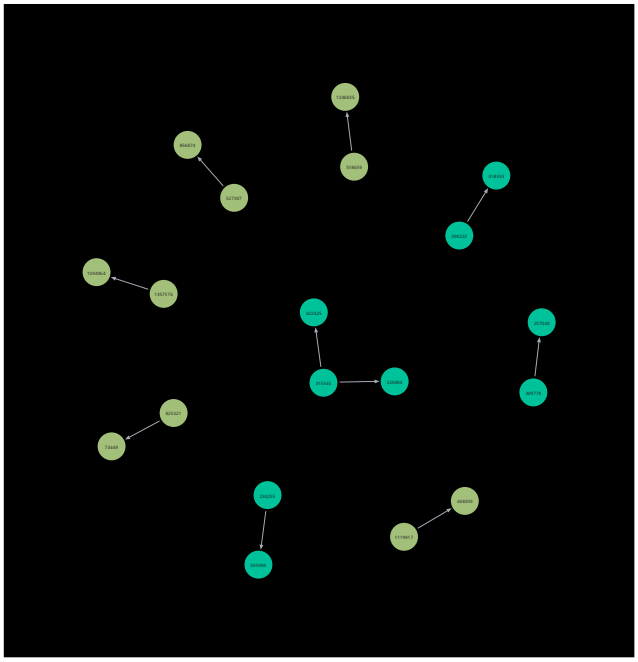
MATCH (i1:Item)-[r:SIMILAR_TO_ITEM]->(i2:Item)
RETURN i1.itemId AS item_1,
    i2.itemId AS item_2,
    r.similarity AS similarity
ORDER BY similarity DESC
LIMIT 5;
```

MATCH mencocokkan pasangan simpul dan relasi similarity; RETURN memilih ID kedua simpul dan nilai similarity; ORDER BY similarity DESC mengurutkan dari nilai tertinggi; LIMIT 5 membatasi hasil menjadi lima record.

User-User :



Item-Item :



7(b). Menuliskan similarity pada graf yang telah ada

Relasi similarity diimpor dari CSV menggunakan LOAD CSV dan disimpan sebagai properti r.similarity.

```
LOAD CSV WITH HEADERS FROM 'file:///similarity_user_top5.csv' AS row
MERGE (u1:Visitor {visitorId: toInteger(row.visitorid_1)})
MERGE (u2:Visitor {visitorId: toInteger(row.visitorid_2)})
MERGE (u1)-[r:SIMILAR_TO_USER]->(u2)
SET r.similarity = toFloat(row.similarity)
RETURN u1.visitorId, u2.visitorId, r.similarity
ORDER BY r.similarity DESC;

LOAD CSV WITH HEADERS FROM 'file:///similarity_item_top5.csv' AS row
MERGE (i1:Item {itemId: toInteger(row.itemid_1)})
MERGE (i2:Item {itemId: toInteger(row.itemid_2)})
MERGE (i1)-[r:SIMILAR_TO_ITEM]->(i2)
SET r.similarity = toFloat(row.similarity)
RETURN i1.itemId, i2.itemId, r.similarity
ORDER BY r.similarity DESC;
```

MERGE mencari atau membuat simpul/pasangan relasi; toInteger mengubah ID ke integer; toFloat mengubah similarity menjadi angka desimal; SET menyimpan similarity sebagai properti relasi.

8. Kondisi Graf Sebelum dan Sesudah Perhitungan Similarity

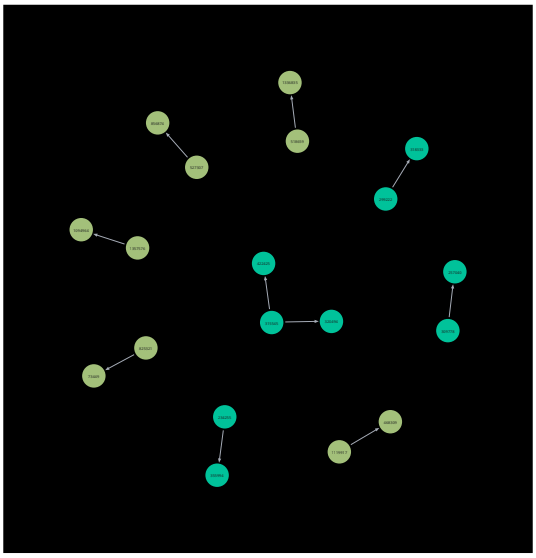
Untuk membandingkan kondisi, gunakan jenis relasi interaksi sebagai baseline sebelum similarity, lalu tampilkan relasi interaksi beserta SIMILAR_TO_USER dan SIMILAR_TO_ITEM setelah proses similarity.

Sebelum similarity: graf interaksi

```
MATCH (v:Visitor)-[r]->(i:Item)
WHERE type(r) IN ['VIEWED', 'ADDED_TO_CART', 'BOUGHT']
RETURN v, r, i
LIMIT 100;

MATCH ()-[r]->()
WHERE type(r) IN ['VIEWED', 'ADDED_TO_CART', 'BOUGHT']
RETURN type(r) AS jenis_relasi, count(r) AS jumlah_relasi
ORDER BY jumlah_relasi DESC;
```

Hasil baseline yang dilaporkan: total 1.048.446 relasi interaksi (VIEWED, ADDED_TO_CART, BOUGHT). Ini merupakan rekonstruksi baseline dengan memfilter jenis relasi, bukan snapshot historis yang disimpan sebelum import.



Sesudah similarity: relasi similarity

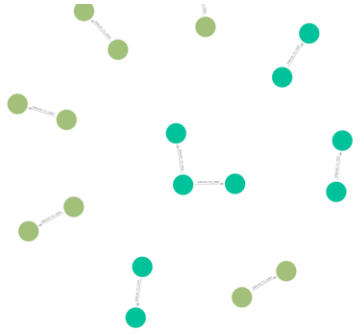
```
MATCH (a)-[r]->(b)
WHERE type(r) IN ['SIMILAR_TO_USER', 'SIMILAR_TO_ITEM']
RETURN a, r, b
ORDER BY r.similarity DESC;
```

Hasil yang dilaporkan: 5 relasi SIMILAR_TO_USER dan 5 relasi SIMILAR_TO_ITEM, sehingga total relasi bertambah dari 1.048.446 menjadi 1.048.456.

Sesudah similarity: tampilkan gabungan graf

```
MATCH (a)-[r]->(b)
WHERE type(r) IN [
 'VIEWED', 'ADDED_TO_CART', 'BOUGHT',
 'SIMILAR_TO_USER', 'SIMILAR_TO_ITEM'
]
RETURN a, r, b
LIMIT 100;
```

Query gabungan menampilkan contoh relasi interaksi dan similarity.



Tabel Perbandingan Sebelum dan Sesudah

Jenis relasi	Sebelum	Sesudah	Catatan
Relasi interaksi	1.048.446	1.048.446	Tidak berubah akibat penambahan relasi similarity
SIMILAR_TO_USER	0	5	Lima pasangan user-user diimpor
SIMILAR_TO_ITEM	0	5	Lima pasangan item-item diimpor
Total relasi	1.048.446	1.048.456	Bertambah 10 relasi

Analytics: Rekomendasi KNN dan Evaluasi

1(a). Pemilihan user dan KNN

User dipilih secara acak dan dapat direproduksi menggunakan NumPy dengan random state 42. Dari 10.332 kandidat user, user yang terpilih adalah 126902. Model menggunakan User-Based KNN dengan k = 5 dan cosine similarity.

Tetangga	Visitor ID	Cosine similarity
1	868560	0.5774
2	42979	0.5774
3	3417	0.5774
4	382724	0.4082
5	900253	0.3333

1(b). Tiga item rekomendasi teratas

Peringkat	ID item	Skor rekomendasi
1	158264	0.4082
2	176019	0.3333
3	426894	0.3333

2(a). Hit@5

Item aktual user 126902 pada testing.csv adalah 434782. Tidak satu pun dari tiga item rekomendasi teratas cocok dengan item aktual tersebut. Output skrip melaporkan Hit@5 = 0.

Definisi yang digunakan: Hit@5 = 1 jika minimal satu dari lima item rekomendasi cocok dengan item aktual pada testing, dan 0 jika tidak ada yang cocok.

2(b). NDCG@5

Jumlah item relevan di testing untuk user ini adalah 1, yaitu item 434782. Tidak ada item relevan pada daftar rekomendasi, sehingga DCG@5 = 0. Karena terdapat satu item relevan, IDCG@5 = 1/log2(2) = 1. Dengan demikian NDCG@5 = 0/1 = 0,0000.

Ringkasan hasil Analytics

Metrik	Hasil
User terpilih	126902
Random state	42
k	5
Hit@5	0
NDCG@5	0.0000

Interpretasi: untuk user yang dipilih, model tidak berhasil merekomendasikan item yang muncul pada data testing. Hasil untuk satu user tidak cukup untuk menyimpulkan performa model pada keseluruhan populasi user.